

Ablation benchmark: 5 arms (issue #1337)

Modelo: deepseek/deepseek-v4.1-flash · braços: normal, mapper, devcli, mapper-devcli, simplicio

t1

- Menor custo: `normal` (\$0.00030 calculado, \$0.00048 cobrado, 1/1 ok)
- Mais rápido: `normal` (48.0s, 1/1 ok)

Total

arm	ok/n	turns	wall (s)	custo calculado	custo cobrado	cache hit	custo sem cache	economia do cache	tokens prompt	tokens cache	tokens completion
normal	1/1	2	48.0	\$0.00030	\$0.00048	60.8%	\$0.00062	\$0.00031	15153	9216	302
mapper	1/1	7	60.0	\$0.00080	\$0.00521	85.9%	\$0.00292	\$0.00212	72602	62336	1292
mapper-devcli	1/1	12	102.8	\$0.00233	\$0.01397	88.5%	\$0.01040	\$0.00807	268186	237440	3489
simplicio	1/1	13	134.1	\$0.00300	\$0.01119	81.8%	\$0.00886	\$0.00585	210576	172160	5129
devcli	1/1	33	323.2	\$0.01389	\$0.07648	71.6%	\$0.03760	\$0.02371	973885	697472	12115

t4

- Menor custo: `normal` (\$0.00172 calculado, \$0.00914 cobrado, 4/4 ok)
- Mais rápido: `normal` (208.1s, 4/4 ok)

Total

arm	ok/n	turns	wall (s)	custo calculado	custo cobrado	cache hit	custo sem cache	economia do cache	tokens prompt	tokens cache	tokens completion
normal	4/4	11	208.1	\$0.00172	\$0.00914	59.4%	\$0.00344	\$0.00172	85137	50560	1586
mapper	4/4	27	296.4	\$0.00385	\$0.01294	82.2%	\$0.01236	\$0.00852	304746	250496	5849
simplicio	4/4	44	406.1	\$0.00739	\$0.04429	87.2%	\$0.02674	\$0.01936	652661	569344	13448
devcli	4/4	71	1345.9	\$0.01237	\$0.02344	90.6%	\$0.05380	\$0.04143	1345236	1218432	23162
mapper-devcli	4/4	59	644.7	\$0.01267	\$0.10650	85.0%	\$0.05316	\$0.04049	1400865	1190784	14240

Criação (create)

arm	ok/n	turns	wall (s)	custo calculado	custo cobrado	cache hit	custo sem cache	economia do cache	tokens prompt	tokens cache	tokens completion
normal	2/2	4	100.1	\$0.00094	\$0.00207	35.7%	\$0.00131	\$0.00037	30515	10880	850
mapper	2/2	12	128.6	\$0.00188	\$0.00660	76.3%	\$0.00543	\$0.00355	136812	104320	2196
simplicio	2/2	23	193.4	\$0.00376	\$0.02565	89.3%	\$0.01411	\$0.01035	340745	304384	7517
devcli	2/2	25	276.9	\$0.00389	\$0.00924	89.2%	\$0.01492	\$0.01103	363813	324480	7538
mapper-devcli	2/2	29	329.2	\$0.00736	\$0.06393	80.1%	\$0.02639	\$0.01903	698691	559616	6663

Edição (edit)

arm	ok/n	turns	wall (s)	custo calculado	custo cobrado	cache hit	custo sem cache	economia do cache	tokens prompt	tokens cache	tokens completion
normal	2/2	7	108.1	\$0.00078	\$0.00707	72.6%	\$0.00213	\$0.00135	54622	39680	736
mapper	2/2	15	167.7	\$0.00197	\$0.00634	87.0%	\$0.00694	\$0.00497	167934	146176	3653
simplicio	2/2	21	212.7	\$0.00363	\$0.01865	84.9%	\$0.01264	\$0.00901	311916	264960	5931
mapper-devcli	2/2	30	315.6	\$0.00531	\$0.04256	89.9%	\$0.02677	\$0.02146	702174	631168	7577
devcli	2/2	46	1068.9	\$0.00849	\$0.01420	91.1%	\$0.03888	\$0.03039	981423	893952	15624

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: `openrouter/deepseek/deepseek-v4.1-flash` · Data: 2026-09-26 · Commit (main): `f7f43e32` · Modo: **sequencial (uma sessão por tarefa)** · Política de esforço: `opencode-managed` (no `per-call reasoning-effort` control via the CLI)

Veredito: normal: 1/1 tarefas, 48.4s, US\$ 0.00048 | mapper: 1/1 tarefas, 60.3s, US\$ 0.00521 | devcli: 1/1 tarefas, 323.7s, US\$ 0.07648 | mapper-devcli: 1/1 tarefas, 103.2s, US\$ 0.01397 | simplicio: 1/1 tarefas, 134.5s, US\$ 0.01119

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	mapper	devcli	mapper-devcli	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	1/1	1/1	1/1	
Tempo (s)	48.0	60.0	323.2	102.8	134.1	-86.1 (-179.4%)
Turnos de LLM	2	7	33	12	13	-11 (-550.0%)
Comandos executados	0	3	31	12	9	-9 (n/a)
... dos quais simplicio-*	0	0	22	10	2	
CPU total (comandos, s)	0.00	0.00	0.00	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	0.0	0.0	0.0	
Tokens prompt (não cacheado)	5937	10266	276413	30746	38416	-32479 (-547.1%)
Tokens prompt (cacheado)	9216	62336	697472	237440	172160	
Tokens completion	287	787	4735	2113	2012	-1725 (-601.0%)
Tokens de raciocínio	15	505	7380	1376	3117	-3102 (-20680.0%)
Custo (USD)	\$0.00048	\$0.00521	\$0.07648	\$0.01397	\$0.01119	\$-0.01071 (-2227.9%)
Invocações do checker pelo próprio agente	0	1	7	1	0	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	2	0	0	0
mapper	7	0	0	0
devcli	33	0	0	0
mapper-devcli	12	0	0	0
simplicio	13	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Somente criação (mesma sessão)

Métrica	normal	mapper	devcli	mapper-devcli	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	1/1	1/1	1/1	
Tempo (s)	48.0	60.0	323.2	102.8	134.1	-86.1 (-179.4%)
Turnos de LLM	2	7	33	12	13	-11 (-550.0%)
Comandos executados	0	3	31	12	9	-9 (n/a)
... dos quais simplicio-*	0	0	22	10	2	
CPU total (comandos, s)	0.00	0.00	0.00	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	0.0	0.0	0.0	
Tokens prompt (não cacheado)	5937	10266	276413	30746	38416	-32479 (-547.1%)
Tokens prompt (cacheado)	9216	62336	697472	237440	172160	
Tokens completion	287	787	4735	2113	2012	-1725 (-601.0%)
Tokens de raciocínio	15	505	7380	1376	3117	-3102 (-20680.0%)
Custo (USD)	\$0.00048	\$0.00521	\$0.07648	\$0.01397	\$0.01119	\$-0.01071 (-2227.9%)
Invocações do checker pelo próprio agente	0	1	7	1	0	

Este conjunto não tem tarefa de edição.

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
--------	--------	------------	------------	-------------	--------------------	-----------


Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.000481	\$0.000305	\$0.000208	\$0.000009	\$0.000088	\$0.000313	60.8%	1/1
mapper	create	\$0.005209	\$0.000796	\$0.000359	\$0.000062	\$0.000375	\$0.002119	85.9%	1/1
devcli	create	\$0.076476	\$0.013885	\$0.009674	\$0.000697	\$0.003513	\$0.023714	71.6%	1/1
mapper-devcli	create	\$0.013967	\$0.002325	\$0.001076	\$0.000237	\$0.001012	\$0.008073	88.5%	1/1
simplicio	create	\$0.011192	\$0.003004	\$0.001345	\$0.000172	\$0.001487	\$0.005853	81.8%	1/1

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	+31.1s
2026-09-26	mapper	n/d
2026-09-26	devcli	n/d
2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+25.1s
2026-09-26	normal	+30.8s
2026-09-26	mapper	n/d
2026-09-26	devcli	n/d
2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+75.2s
2026-09-26	normal	+18.7s
2026-09-26	mapper	n/d
2026-09-26	devcli	n/d
2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+84.8s
2026-09-26	normal	+30.1s
2026-09-26	mapper	n/d
2026-09-26	devcli	n/d
2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+113.9s
2026-09-26	normal	+33.3s
2026-09-26	mapper	n/d

2026-09-26	devcli	n/d
2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+65.0s

Gerado automaticamente a partir de results.json (dados reais, sem números fabricados). Nenhuma chave de API foi impressa ou registrada neste relatório.

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-26 · Commit (main): f7f43e32 · Modo: sequencial (uma sessão por tarefa) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

Veredito: normal: 4/4 tarefas, 209.7s, US\$ 0.00914 | mapper: 4/4 tarefas, 298.4s, US\$ 0.01294 | devcli: 4/4 tarefas, 1349.8s, US\$ 0.02344 | mapper-devcli: 4/4 tarefas, 646.7s, US\$ 0.10650 | simplicio: 4/4 tarefas, 407.6s, US\$ 0.04429

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	mapper	devcli	mapper-devcli	simplicio	Economia com simplicio
Tarefas concluídas	4/4	4/4	4/4	4/4	4/4	
Tempo (s)	208.1	296.4	1345.9	644.7	406.1	-198.0 (-95.1%)
Turnos de LLM	11	27	71	59	44	-33 (-300.0%)
Comandos executados	0	10	69	55	28	-28 (n/a)
... dos quais simplicio-*	0	0	42	50	8	
CPU total (comandos, s)	0.00	0.00	0.00	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	0.0	0.0	0.0	
Tokens prompt (não cacheado)	34577	54250	126804	210081	83317	-48740 (-141.0%)
Tokens prompt (cacheado)	50560	250496	1218432	1190784	569344	
Tokens completion	1437	3529	10776	8228	6460	-5023 (-349.6%)
Tokens de raciocínio	149	2320	12386	6012	6988	-6839 (-4589.9%)
Custo (USD)	\$0.00914	\$0.01294	\$0.02344	\$0.10650	\$0.04429	\$-0.03515 (-384.6%)
Invocações do checker pelo próprio agente	0	1	5	2	0	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	11	0	0	0
mapper	27	0	0	0
devcli	71	0	0	0
mapper-devcli	59	0	0	0
simplicio	44	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Somente criação (mesma sessão)

Métrica	normal	mapper	devcli	mapper-devcli	simplicio	Economia com simplicio
Tarefas concluídas	2/2	2/2	2/2	2/2	2/2	
Tempo (s)	100.1	128.6	276.9	329.2	193.4	-93.4 (-93.3%)
Turnos de LLM	4	12	25	29	23	-19 (-475.0%)
Comandos executados	0	6	18	26	15	-15 (n/a)
... dos quais simplicio-*	0	0	16	23	4	
CPU total (comandos, s)	0.00	0.00	0.00	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	0.0	0.0	0.0	
Tokens prompt (não cacheado)	19635	32492	39333	139075	36361	-16726 (-85.2%)
Tokens prompt (cacheado)	10880	104320	324480	559616	304384	
Tokens completion	807	1693	3617	4089	3517	-2710 (-335.8%)
Tokens de raciocínio	43	503	3921	2574	4000	-3957 (-9202.3%)
Custo (USD)	\$0.00207	\$0.00660	\$0.00924	\$0.06393	\$0.02565	\$-0.02358 (-1139.8%)
Invocações do checker pelo próprio agente	0	1	1	1	0	

Somente edição (mesma sessão)

Métrica	normal	mapper	devcli	mapper-devcli	simplicio	Economia com simplicio
Tarefas concluídas	2/2	2/2	2/2	2/2	2/2	
Tempo (s)	108.1	167.7	1068.9	315.6	212.7	-104.6 (-96.8%)
Turnos de LLM	7	15	46	30	21	-14 (-200.0%)

Comandos executados	0	4	51	29	13	-13 (n/a)
... dos quais simplicio-*	0	0	26	27	4	
CPU total (comandos, s)	0.00	0.00	0.00	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	0.0	0.0	0.0	
Tokens prompt (não cacheado)	14942	21758	87471	71006	46956	-32014 (-214.3%)
Tokens prompt (cacheado)	39680	146176	893952	631168	264960	
Tokens completion	630	1836	7159	4139	2943	-2313 (-367.1%)
Tokens de raciocínio	106	1817	8465	3438	2988	-2882 (-2718.9%)
Custo (USD)	\$0.00707	\$0.00634	\$0.01420	\$0.04256	\$0.01865	\$-0.01157 (-163.7%)
Invocações do checker pelo próprio agente	0	0	4	1	0	

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000000350	0.0000002900	0.0000000010	-	-	2026-09-27T00:04:15.771742+00:00


Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.002069	\$0.000945	\$0.000687	\$0.000011	\$0.000246	\$0.000370	35.7%	1/2
normal	edit	\$0.007071	\$0.000776	\$0.000523	\$0.000040	\$0.000213	\$0.001349	72.6%	2/2
mapper	create	\$0.006599	\$0.001878	\$0.001137	\$0.000104	\$0.000637	\$0.003547	76.3%	2/2
mapper	edit	\$0.006340	\$0.001967	\$0.000762	\$0.000146	\$0.001059	\$0.004970	87.0%	2/2
devcli	create	\$0.009244	\$0.003887	\$0.001377	\$0.000324	\$0.002186	\$0.011032	89.2%	2/2
devcli	edit	\$0.014196	\$0.008486	\$0.003061	\$0.000894	\$0.004531	\$0.030394	91.1%	2/2
mapper-devcli	create	\$0.063931	\$0.007360	\$0.004868	\$0.000560	\$0.001932	\$0.019027	80.1%	2/2
mapper-devcli	edit	\$0.042564	\$0.005314	\$0.002485	\$0.000631	\$0.002197	\$0.021460	89.9%	2/2
simplicio	create	\$0.025647	\$0.003757	\$0.001273	\$0.000304	\$0.002180	\$0.010349	89.3%	2/2
simplicio	edit	\$0.018645	\$0.003628	\$0.001643	\$0.000265	\$0.001720	\$0.009009	84.9%	2/2

Gate de cache por chamada: FALHOU — primeira chamada fria: tarefa 2, turno 3 (11217 tokens de prompt; anterior 11028). Causa provável: prefixo mudou antes do fim da chamada anterior (conteúdo volátil no topo ou troca de provedor).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	+91.0s
2026-09-26	mapper	n/d
2026-09-26	devcli	n/d

2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+5.7s
2026-09-26	normal	+117.3s
2026-09-26	mapper	n/d
2026-09-26	devcli	n/d
2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+44.0s
2026-09-26	normal	+141.2s
2026-09-26	mapper	n/d
2026-09-26	devcli	n/d
2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+250.8s
2026-09-26	normal	+150.5s
2026-09-26	mapper	n/d
2026-09-26	devcli	n/d
2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+258.7s
2026-09-26	normal	+12.8s
2026-09-26	mapper	n/d
2026-09-26	devcli	n/d
2026-09-26	mapper-devcli	n/d
2026-09-26	simplicio	+45.8s

Gerado automaticamente a partir de results.json (dados reais, sem números fabricados). Nenhuma chave de API foi impressa ou registrada neste relatório.