

Benchmark A/B — 2 tarefas (criar e editar cadastro.html)

Um braço sem a skill simplicio-loop e um braço com a skill. Sessão sequencial.

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: `openrouter/deepseek/deepseek-v4.1-flash` · Data: 2026-09-27 · Commit (main): 5b9bae15 · Modo: **sequencial (uma sessão por tarefa)** · Política de esforço: `opencode-managed` (no `per-call reasoning-effort` control via the CLI)

`simplicio-cli 0.18.16` `simplicio-loop 3.43.16` `simplicio-mapper 0.26.34`

Veredito: normal: 2/2 tarefas, 38.7s, US\$ 0.00308 | simplicio: 2/2 tarefas, 535.9s, US\$ 0.08031

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	2/2	2/2	
Tempo (s)	38.5	535.9	-497.4 (-1292.8%)
Turnos de LLM	6	95	-89 (-1483.3%)
Comandos executados	0	92	-92 (n/a)
... dos quais simplicio-*	0	43	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	18440	115625	-97185 (-527.0%)
Tokens prompt (cacheado)	28416	4210176	
Tokens completion	767	16090	-15323 (-1997.8%)
Tokens de raciocínio	32	22745	-22713 (-70978.1%)
Custo (USD)	\$0.00308	\$0.08031	\$-0.07723 (-2509.3%)
Invocações do checker pelo próprio agente	0	7	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	6	0	0	0
simplicio	95	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Somente criação (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	
Tempo (s)	17.7	309.7	-292.0 (-1654.3%)
Turnos de LLM	2	71	-69 (-3450.0%)
Comandos executados	0	60	-60 (n/a)
... dos quais simplicio-*	0	29	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	11909	63811	-51902 (-435.8%)
Tokens prompt (cacheado)	3456	3164928	
Tokens completion	315	9664	-9349 (-2967.9%)
Tokens de raciocínio	25	15456	-15431 (-61724.0%)
Custo (USD)	\$0.00000	\$0.04376	\$-0.04376 (n/a)
Invocações do checker pelo próprio agente	0	4	

Somente edição (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	
Tempo (s)	20.8	226.2	-205.3 (-986.3%)
Turnos de LLM	4	24	-20 (-500.0%)

Comandos executados	0	32	-32 (n/a)
... dos quais simplicio-*	0	14	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	6531	51814	-45283 (-693.4%)
Tokens prompt (cacheado)	24960	1045248	
Tokens completion	452	6426	-5974 (-1321.7%)
Tokens de raciocínio	7	7289	-7282 (-104028.6%)
Custo (USD)	\$0.00308	\$0.03655	\$-0.03347 (-1087.4%)
Invocações do checker pelo próprio agente	0	3	

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000000297	0.0000006000	0.0000000268	-	-	2026-09-28T01:35:06.577486+00:00


Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.000000	\$0.000651	\$0.000354	\$0.000093	\$0.000204	\$0.000010	22.5%	1/1
normal	edit	\$0.003078	\$0.001138	\$0.000194	\$0.000668	\$0.000275	\$0.000074	79.3%	1/1
simplicio	create	\$0.043763	\$0.101727	\$0.001898	\$0.084757	\$0.015072	\$0.009400	98.0%	1/1
simplicio	edit	\$0.036548	\$0.037762	\$0.001541	\$0.027992	\$0.008229	\$0.003104	95.3%	0/1

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
sem execuções anteriores nesta pasta de resultados		

CPU e RAM do processo (medido fora do OpenCode)

O relatório padrão deixa CPU/RAM de comando em zero: o OpenCode não entrega rusage por comando, e o pico via /proc não existe no macOS. Esta tabela é a medição externa da árvore de processos (ps a cada 0,25 s), excluindo o amostrador. CPU é a soma do tempo de CPU dos processos da árvore. Pico da árvore soma o RSS residente no instante; pico do maior processo é o RSS de um único processo. A edição do braço simplicio foi repetida uma vez: a primeira tentativa morreu com timeout de stream do provedor e o harness descartou os eventos porque o opencode saiu com código 1.

braço	tarefa	CPU (s)	pico RSS árvore (MB)	pico RSS processo (MB)	amostras
normal	1	4.37	591.3	575.7	94

normal	2	3.38	614.2	588.7	70
simplicio	1	59.57	725.0	645.5	1109
simplicio	2	59.45	648.0	621.6	825
normal	1+2	7.75	614.2	588.7	
simplicio	1+2	119.02	725.0	645.5	

Gerado automaticamente a partir de results.json (dados reais, sem números fabricados). Nenhuma chave de API foi impressa ou registrada neste relatório.