

Benchmark A/B: matriz padrão (bench/llm_ab/STANDARD.md)

Modelo: deepseek/deepseek-v4.1-flash · braços: normal, simplicio

Resumo (normal vs simplicio)

combinação	normal ok	turnos	tempo (s)	custo cobrado	custo calculado	sinalizados	cache hit	custo sem cache	economia do cache	simplicio ok	turnos	tempo (s)	custo cobrado	custo calculado	sinalizados	cache hit	custo sem cache	economia do cache	economia de custo cobrado com simplicio
t1 · total	1/1	2	19.4	\$0.00262	\$0.00262	1	59.2%	\$0.00532	\$0.00271	1/1	1	14.6	\$0.00363	\$0.00363	0	△ 0.0% (<80%)	\$0.00363	\$0.00000	\$-0.00101 (-38.8%)
t1 · criação	1/1	2	19.4	\$0.00262	\$0.00262	1	59.2%	\$0.00532	\$0.00271	1/1	1	14.6	\$0.00363	\$0.00363	0	△ 0.0% (<80%)	\$0.00363	\$0.00000	\$-0.00101 (-38.8%)
t4 · total	4/4	12	95.3	\$0.00915	\$0.00653	4	84.7%	\$0.02978	\$0.02326	4/4	4	15.0	\$0.00463	\$0.00463	0	△ 49.6% (<80%)	\$0.00719	\$0.00256	\$0.00452 (49.4%)
t4 · criação	2/2	4	30.9	\$0.00271	\$0.00450	2	60.1%	\$0.00992	\$0.00542	2/2	4	15.0	\$0.00463	\$0.00463	0	△ 49.6% (<80%)	\$0.00719	\$0.00256	\$-0.00192 (-70.8%)
t4 · edição	2/2	8	64.4	\$0.00644	\$0.00202	2	96.6%	\$0.01986	\$0.01784	2/2	0	0.0	\$0.00000	\$0.00000	0	△ 0.0% (<80%)	\$0.00000	\$0.00000	\$0.00644 (100.0%)

Custo cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é 3+ leituras seguidas sem variar, nunca o primeiro movimento), ou o próprio custo calculado quando o uso nunca assenta dentro da janela (`cost_source = computed-from-tokens`). Custo calculado = os mesmos tokens pelo preço da própria execução (prompt/cache/completion), sempre presente, mesmo para runs antigas sem o campo (recalculado aqui a partir dos tokens armazenados, nunca editando o `results/*.json` histórico). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%. Custo sem cache = os mesmos tokens ao preço cheio de prompt. Economia do cache = diferença, pelo preço de cache read da própria execução. Batch = uma sessão para todas as tarefas, por isso sem linhas de criação/edição; veja a execução sequencial do mesmo conjunto.

- [t1](#) — 2026-09-28-146a6931-t1.json
- [t4](#) — 2026-09-28-146a6931-t4.json

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-28 · Commit (main): 146a6931 · Modo: sequencial (uma sessão por tarefa) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

simplicio-loop 3.44.0

Veredito: normal: 1/1 tarefas, 19.5s, US\$ 0.00262 | simplicio: 1/1 tarefas, 14.6s, US\$ 0.00363

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	
Tempo (s)	19.4	14.6	4.8 (25.0%)
Turnos de LLM	2	1	1 (50.0%)
Comandos executados	0	2	-2 (n/a)
... dos quais simplicio-*	0	2	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	6362	3588	2774 (43.6%)
Tokens prompt (cacheado)	9216	0	
Tokens completion	463	316	147 (31.8%)
Tokens de raciocínio	80	1812	-1732 (-2165.0%)
Custo (USD)	\$0.00262	\$0.00363	\$-0.00101 (-38.8%)
Invocações do checker pelo próprio agente	0	0	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	2	0	0	0
simplicio	1	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Somente criação (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	
Tempo (s)	19.4	14.6	4.8 (25.0%)
Turnos de LLM	2	1	1 (50.0%)
Comandos executados	0	2	-2 (n/a)
... dos quais simplicio-*	0	2	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	6362	3588	2774 (43.6%)
Tokens prompt (cacheado)	9216	0	
Tokens completion	463	316	147 (31.8%)
Tokens de raciocínio	80	1812	-1732 (-2165.0%)
Custo (USD)	\$0.00262	\$0.00363	\$-0.00101 (-38.8%)
Invocações do checker pelo próprio agente	0	0	

Este conjunto não tem tarefa de edição.

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000003000	0.0000012000	0.0000000060	-	-	2026-09-28T21:15:33.350972+00:00


Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.000000	\$0.002616	\$0.001909	\$0.000055	\$0.000652	\$0.002710	59.2%	1/1
simplicio	create	\$0.003630	\$0.003630	\$0.001076	\$0.000000	\$0.002554	\$0.000000	0.0%	0/1

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	+2.2s
2026-09-26	simplicio	-94.9s
2026-09-26	normal	+2.0s
2026-09-26	simplicio	-44.8s
2026-09-26	normal	-10.2s
2026-09-26	simplicio	-35.2s
2026-09-26	normal	+1.3s
2026-09-26	simplicio	-6.1s
2026-09-26	normal	+4.5s
2026-09-26	simplicio	-54.9s
2026-09-27	normal	+1.1s
2026-09-27	simplicio	-70.9s
2026-09-27	normal	+1.0s
2026-09-27	simplicio	-43.7s
2026-09-28	normal	+5.0s
2026-09-28	simplicio	+6.0s
2026-09-28	normal	+1.3s
2026-09-28	simplicio	+12.0s

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-28 · Commit (main): 146a6931 · Modo: sequencial (uma sessão por tarefa) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

simplicio-loop 3.44.0

Veredito: normal: 4/4 tarefas, 95.9s, US\$ 0.00915 | simplicio: 4/4 tarefas, 15.0s, US\$ 0.00463

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	4/4	4/4	
Tempo (s)	95.3	15.0	80.2 (84.2%)
Turnos de LLM	12	4	8 (66.7%)
Comandos executados	0	8	-8 (n/a)
... dos quais simplicio-*	0	8	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	14326	8839	5487 (38.3%)
Tokens prompt (cacheado)	79104	8704	
Tokens completion	1420	971	449 (31.6%)
Tokens de raciocínio	42	635	-593 (-1411.9%)
Custo (USD)	\$0.00915	\$0.00463	\$0.00452 (49.4%)
Invocações do checker pelo próprio agente	0	0	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	12	0	0	0
simplicio	4	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Somente criação (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	2/2	2/2	
Tempo (s)	30.9	15.0	15.9 (51.4%)
Turnos de LLM	4	4	0 (0.0%)
Comandos executados	0	8	-8 (n/a)
... dos quais simplicio-*	0	8	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	12216	8839	3377 (27.6%)
Tokens prompt (cacheado)	18432	8704	
Tokens completion	583	971	-388 (-66.5%)
Tokens de raciocínio	24	635	-611 (-2545.8%)
Custo (USD)	\$0.00271	\$0.00463	\$-0.00192 (-70.8%)
Invocações do checker pelo próprio agente	0	0	

Somente edição (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	2/2	2/2	
Tempo (s)	64.4	0.0	64.4 (100.0%)
Turnos de LLM	8	0	8 (100.0%)
Comandos executados	0	0	0 (n/a)
... dos quais simplicio-*	0	0	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	2110	0	2110 (100.0%)
Tokens prompt (cacheado)	60672	0	
Tokens completion	837	0	837 (100.0%)
Tokens de raciocínio	18	0	18 (100.0%)
Custo (USD)	\$0.00644	\$0.00000	\$0.00644 (100.0%)
Invocações do checker pelo próprio agente	0	0	

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000003000	0.0000012000	0.0000000060	-	-	2026-09-28T21:16:29.671311+00:00

Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)


Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.000425	\$0.004504	\$0.003665	\$0.000111	\$0.000728	\$0.005419	60.1%	2/2

normal	edit	\$0.006438	\$0.002023	\$0.000633	\$0.000364	\$0.001026	\$0.017838	96.6%	2/2
simplicio	create	\$0.004631	\$0.004631	\$0.002652	\$0.000052	\$0.001927	\$0.002559	49.6%	0/2
simplicio	edit	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	0.0%	0/2

Gate de cache por chamada: FALHOU — primeira chamada fria: tarefa 1, turno 2 (4257 tokens de prompt; anterior 3588). Causa provável: prefixo mudou antes do fim da chamada anterior (conteúdo volátil no topo ou troca de provedor).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	-22.8s
2026-09-26	simplicio	-386.9s
2026-09-26	normal	+3.6s
2026-09-26	simplicio	-348.6s
2026-09-26	normal	+27.4s
2026-09-26	simplicio	-141.8s
2026-09-26	normal	+36.7s
2026-09-26	simplicio	-133.9s
2026-09-27	normal	-40.6s
2026-09-27	simplicio	-268.8s
2026-09-28	normal	+7.0s
2026-09-28	simplicio	-10.9s
2026-09-28	normal	-12.5s
2026-09-28	simplicio	-78.7s