

Benchmark A/B: matriz padrão (bench/llm_ab/STANDARD.md)

Modelo: deepseek/deepseek-v4.1-flash · braços: normal, simplicio

Resumo (normal vs simplicio)

combinação	normal ok	turnos	tempo (s)	custo cobrado	custo calculado	signalizados	cache hit	custo sem cache	economia do cache	simplicio ok	turnos	tempo (s)	custo cobrado	custo calculado	signalizados	cache hit	custo sem cache	economia do cache	economia de custo cobrado com simplicio
t1-batch · total	1/1	2	44.0	\$0.00048	\$0.00039	1	47.9%	\$0.00064	\$0.00025	1/1	12	89.9	\$0.01796	[△] \$0.00468 (<80%)	1	43.7%	\$0.00728	\$0.00260	\$-0.01748 (-3670.8%)
t4 · total	4/4	12	194.8	\$0.01234	\$0.00206	3	53.4%	\$0.00375	\$0.00168	4/4	45	360.0	\$0.03523	\$0.00649	4	90.3%	\$0.02796	\$0.02146	\$-0.02290 (-185.6%)
t4 · criação	2/2	4	94.8	\$0.00327	\$0.00108	1	23.5%	\$0.00133	\$0.00024	2/2	26	184.6	\$0.02180	\$0.00363	2	91.8%	\$0.01695	\$0.01332	\$-0.01853 (-566.5%)
t4 · edição	2/2	8	100.0	\$0.00906	\$0.00098	2	68.0%	\$0.00242	\$0.00144	2/2	19	175.4	\$0.01343	\$0.00287	2	88.0%	\$0.01101	\$0.00814	\$-0.00437 (-48.2%)
t4-batch · total	4/4	12	164.8	\$0.00171	\$0.00115	1	89.9%	\$0.00564	\$0.00449	4/4	13	161.2	\$0.00682	\$0.00298	1	92.2%	\$0.01066	\$0.00768	\$-0.00511 (-297.8%)

Custo cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é 3+ leituras seguidas sem variar, nunca o primeiro movimento), ou o próprio custo calculado quando o uso nunca assenta dentro da janela (``cost_source = computed-from-tokens``). Custo calculado = os mesmos tokens pelo preço da própria execução (prompt/cache/completion), sempre presente, mesmo para runs antigas sem o campo (recalculado aqui a partir dos tokens armazenados, nunca editando o `results/*`.json histórico). Signalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%. Custo sem cache = os mesmos tokens ao preço cheio de prompt. Economia do cache = diferença, pelo preço de cache read da própria execução. Batch = uma sessão para todas as tarefas, por isso sem linhas de criação/edição; veja a execução sequencial do mesmo conjunto.

- [t1-batch](#) — 2026-09-26-f7f43e32-t1-batch.json
- [t4](#) — 2026-09-26-f7f43e32-t4.json
- [t4-batch](#) — 2026-09-26-f7f43e32-t4-batch.json

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-26 · Commit (main): f7f43e32 · Modo: batch (todas as tarefas em uma sessão) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

Veredito: normal: 1/1 tarefas, 44.0s, US\$ 0.00048 | simplicio: 1/1 tarefas, 89.9s, US\$ 0.01796

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	
Tempo (s)	44.0	89.9	-46.0 (-104.6%)
Turnos de LLM	2	12	-10 (-500.0%)
Comandos executados	0	8	-8 (n/a)
... dos quais simplicio-*	0	2	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	7926	98405	-90479 (-1141.5%)
Tokens prompt (cacheado)	7296	76416	
Tokens completion	272	1684	-1412 (-519.1%)
Tokens de raciocínio	101	2306	-2205 (-2183.2%)
Custo (USD)	\$0.00048	\$0.01796	\$-0.01748 (-3670.8%)
Invocações do checker pelo próprio agente	0	2	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	2	0	0	0
simplicio	12	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Modo batch: criação e edição acontecem em **uma única sessão**, então turnos, tempo e custo não são separáveis por tarefa. Os números somente criação / somente edição estão no relatório sequencial do mesmo conjunto (ex.: REPORT-t4.html) e no resumo de REPORT.html.

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000000350	0.0000002900	0.0000000010	-	-	2026-09-26T23:33:46.938104+00:00


Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.000476	\$0.000393	\$0.000277	\$0.000007	\$0.000108	\$0.000248	47.9%	1/1
simplicio	create	\$0.017959	\$0.004678	\$0.003444	\$0.000076	\$0.001157	\$0.002598	43.7%	1/1

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	+26.7s
2026-09-26	simplicio	-19.5s
2026-09-26	normal	+26.4s
2026-09-26	simplicio	+30.6s
2026-09-26	normal	+14.2s
2026-09-26	simplicio	+40.1s
2026-09-26	normal	+25.7s
2026-09-26	simplicio	+69.3s
2026-09-26	normal	+28.9s
2026-09-26	simplicio	+20.4s

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-26 · Commit (main): f7f43e32 · Modo: sequencial (uma sessão por tarefa) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

Veredito: normal: 4/4 tarefas, 196.9s, US\$ 0.01234 | simplicio: 4/4 tarefas, 361.8s, US\$ 0.03523

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	4/4	4/4	
Tempo (s)	194.8	360.0	-165.2 (-84.8%)
Turnos de LLM	12	45	-33 (-275.0%)
Comandos executados	0	28	-28 (n/a)
... dos quais simplicio-*	0	9	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	43299	67684	-24385 (-56.3%)
Tokens prompt (cacheado)	49536	631296	
Tokens completion	1495	6423	-4928 (-329.6%)
Tokens de raciocínio	217	5627	-5410 (-2493.1%)
Custo (USD)	\$0.01234	\$0.03523	\$-0.02290 (-185.6%)
Invocações do checker pelo próprio agente	0	1	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	12	0	0	0
simplicio	45	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Somente criação (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	2/2	2/2	
Tempo (s)	94.8	184.6	-89.8 (-94.7%)
Turnos de LLM	4	26	-22 (-550.0%)
Comandos executados	0	17	-17 (n/a)
... dos quais simplicio-*	0	5	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	23373	35116	-11743 (-50.2%)
Tokens prompt (cacheado)	7168	391808	
Tokens completion	832	3351	-2519 (-302.8%)
Tokens de raciocínio	60	3563	-3503 (-5838.3%)
Custo (USD)	\$0.00327	\$0.02180	\$-0.01853 (-566.5%)
Invocações do checker pelo próprio agente	0	0	

Somente edição (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	2/2	2/2	
Tempo (s)	100.0	175.4	-75.4 (-75.4%)
Turnos de LLM	8	19	-11 (-137.5%)
Comandos executados	0	11	-11 (n/a)
... dos quais simplicio-*	0	4	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	19926	32568	-12642 (-63.4%)
Tokens prompt (cacheado)	42368	239488	
Tokens completion	663	3072	-2409 (-363.4%)
Tokens de raciocínio	157	2064	-1907 (-1214.7%)
Custo (USD)	\$0.00906	\$0.01343	\$-0.00437 (-48.2%)
Invocações do checker pelo próprio agente	0	1	

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000000350	0.0000002900	0.0000000010	-	-	2026-09-26T23:36:24.590704+00:00


Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.003271	\$0.001084	\$0.000818	\$0.000007	\$0.000259	\$0.000244	23.5%	1/2
normal	edit	\$0.009064	\$0.000978	\$0.000697	\$0.000042	\$0.000238	\$0.001441	68.0%	2/2
simplicio	create	\$0.021802	\$0.003626	\$0.001229	\$0.000392	\$0.002005	\$0.013321	91.8%	2/2
simplicio	edit	\$0.013430	\$0.002869	\$0.001140	\$0.000239	\$0.001489	\$0.008143	88.0%	2/2

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	+78.2s
2026-09-26	simplicio	-40.1s
2026-09-26	normal	+104.5s
2026-09-26	simplicio	-1.8s
2026-09-26	normal	+128.4s
2026-09-26	simplicio	+205.0s
2026-09-26	normal	+137.7s
2026-09-26	simplicio	+212.8s

Gerado automaticamente a partir de results.json (dados reais, sem números fabricados). Nenhuma chave de API foi impressa ou registrada neste relatório.

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-26 · Commit (main): f7f43e32 · Modo: batch (todas as tarefas em uma sessão) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

Veredito: normal: 4/4 tarefas, 164.8s, US\$ 0.00171 | simplicio: 4/4 tarefas, 161.2s, US\$ 0.00682

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	4/4	4/4	
Tempo (s)	164.8	161.2	3.7 (2.2%)
Turnos de LLM	12	13	-1 (-8.3%)
Comandos executados	6	8	-2 (-33.3%)
... dos quais simplicio-*	0	2	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	14793	19089	-4296 (-29.0%)
Tokens prompt (cacheado)	132096	225920	
Tokens completion	1524	2509	-985 (-64.6%)
Tokens de raciocínio	213	4676	-4463 (-2095.3%)
Custo (USD)	\$0.00171	\$0.00682	\$-0.00511 (-297.8%)
Invocações do checker pelo próprio agente	2	0	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	12	0	0	0
simplicio	13	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Modo batch: criação e edição acontecem em uma única sessão, então turnos, tempo e custo não são separáveis por tarefa. Os números somente criação / somente edição estão no relatório sequencial do mesmo conjunto (ex.: REPORT-t4.html) e no resumo de REPORT.html.

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000000350	0.0000002900	0.0000000010	-	-	2026-09-26T23:46:06.274185+00:00


Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.001715	\$0.001154	\$0.000518	\$0.000132	\$0.000504	\$0.004491	89.9%	1/2
normal	edit	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	0.0%	0/2
simplicio	create	\$0.006820	\$0.002978	\$0.000668	\$0.000226	\$0.002084	\$0.007681	92.2%	1/2
simplicio	edit	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	0.0%	0/2

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	+46.2s
2026-09-26	simplicio	-240.7s
2026-09-26	normal	+72.5s
2026-09-26	simplicio	-202.5s
2026-09-26	normal	+96.3s
2026-09-26	simplicio	+4.3s
2026-09-26	normal	+105.7s
2026-09-26	simplicio	+12.2s
2026-09-26	normal	-32.0s

2026-09-26	simplicio	-200.6s
------------	-----------	---------

Gerado automaticamente a partir de results.json (dados reais, sem números fabricados). Nenhuma chave de API foi impressa ou registrada neste relatório.