

Benchmark A/B: matriz padrão (bench/llm_ab/STANDARD.md)

Modelo: deepseek/deepseek-v4.1-flash · braços: normal, simplicio

Resumo (normal vs simplicio)

combinação	normal ok	turnos	tempo (s)	custo cobrado	custo calculado	sinalizados	cache hit	custo sem cache	economia do cache	simplicio ok	turnos	tempo (s)	custo cobrado	custo calculado	sinalizados	cache hit	custo sem cache	economia do cache	economia de custo cobrado com simplicio
t1 · total	1/1	2	18.4	\$0.00000	\$0.00037	1	47.3%	\$0.00062	\$0.00024	1/1	10	58.1	\$0.00691	\$0.00169	1	85.4%	\$0.00603	\$0.00433	\$-0.00691 (n/a)
t1 · criação	1/1	2	18.4	\$0.00000	\$0.00037	1	47.3%	\$0.00062	\$0.00024	1/1	10	58.1	\$0.00691	\$0.00169	1	85.4%	\$0.00603	\$0.00433	\$-0.00691 (n/a)
t1-batch · total	1/1	6	27.0	\$0.00330	\$0.00080	1	72.6%	\$0.00217	\$0.00137	1/1	10	47.7	\$0.00839	\$0.00182	1	81.7%	\$0.00617	\$0.00435	\$-0.00509 (-154.3%)
t4 · total	4/4	18	135.8	\$0.04566	\$0.00220	4	73.1%	\$0.00612	\$0.00393	4/4	45	283.2	\$0.04128	\$0.00625	4	89.5%	\$0.02546	\$0.01921	\$0.00438 (9.6%)
t4 · criação	2/2	9	73.2	\$0.01904	\$0.00109	2	78.4%	\$0.00343	\$0.00234	2/2	24	167.0	\$0.02704	\$0.00361	2	87.5%	\$0.01408	\$0.01047	\$-0.00800 (-42.0%)
t4 · edição	2/2	9	62.6	\$0.02662	\$0.00111	2	66.5%	\$0.00269	\$0.00158	2/2	21	116.2	\$0.01424	\$0.00264	2	92.0%	\$0.01138	\$0.00874	\$0.01238 (46.5%)
t4-batch · total	4/4	6	111.5	\$0.00175	\$0.00088	1	81.0%	\$0.00265	\$0.00177	4/4	20	135.2	\$0.01129	\$0.00288	1	92.7%	\$0.01469	\$0.01181	\$-0.00954 (-543.8%)

Custo cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é 3+ leituras seguidas sem variar, nunca o primeiro movimento), ou o próprio custo calculado quando o uso nunca assenta dentro da janela (``cost_source = computed-from-tokens``). Custo calculado = os mesmos tokens pelo preço da própria execução (prompt/cache/completion), sempre presente, mesmo para runs antigas sem o campo (recalculado aqui a partir dos tokens armazenados, nunca editando o `results/*.json` histórico). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%. Custo sem cache = os mesmos tokens ao preço cheio de prompt. Economia do cache = diferença, pelo preço de cache read da própria execução. Batch = uma sessão para todas as tarefas, por isso sem linhas de criação/edição; veja a execução sequencial do mesmo conjunto.

- [t1](#) — 2026-09-27-f7f43e324-t1.json
- [t1-batch](#) — 2026-09-27-f7f43e324-t1-batch.json
- [t4](#) — 2026-09-27-f7f43e324-t4.json
- [t4-batch](#) — 2026-09-27-f7f43e324-t4-batch.json

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-27 · Commit (main): 9165efe04 · Modo: sequencial (uma sessão por tarefa) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

simplicio-cli 0.18.16 · simplicio-loop 3.43.16 · simplicio-mapper 0.26.34

Veredito: normal: 1/1 tarefas, 18.5s, US\$ 0.00000 | simplicio: 1/1 tarefas, 58.3s, US\$ 0.00691

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	
Tempo (s)	18.4	58.1	-39.7 (-216.2%)
Turnos de LLM	2	10	-8 (-400.0%)
Comandos executados	0	6	-6 (n/a)
... dos quais simplicio-*	0	2	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	7986	21857	-13871 (-173.7%)
Tokens prompt (cacheado)	7168	127488	
Tokens completion	286	1617	-1331 (-465.4%)
Tokens de raciocínio	18	1144	-1126 (-6255.6%)
Custo (USD)	\$0.00000	\$0.00691	\$-0.00691 (n/a)
Invocações do checker pelo próprio agente	0	0	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	2	0	0	0
simplicio	10	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Somente criação (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	
Tempo (s)	18.4	58.1	-39.7 (-216.2%)
Turnos de LLM	2	10	-8 (-400.0%)
Comandos executados	0	6	-6 (n/a)
... dos quais simplicio-*	0	2	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	7986	21857	-13871 (-173.7%)
Tokens prompt (cacheado)	7168	127488	
Tokens completion	286	1617	-1331 (-465.4%)
Tokens de raciocínio	18	1144	-1126 (-6255.6%)
Custo (USD)	\$0.00000	\$0.00691	\$-0.00691 (n/a)
Invocações do checker pelo próprio agente	0	0	

Este conjunto não tem tarefa de edição.

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000000350	0.0000002900	0.0000000010	-	-	2026-09-27T01:23:09.428081+00:00




Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.000000	\$0.000375	\$0.000280	\$0.000007	\$0.000088	\$0.000244	47.3%	1/1
simplicio	create	\$0.006906	\$0.001693	\$0.000765	\$0.000127	\$0.000801	\$0.004335	85.4%	1/1

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	+1.2s
2026-09-26	simplicio	-51.1s
2026-09-26	normal	+1.0s
2026-09-26	simplicio	-1.1s
2026-09-26	normal	-11.2s
2026-09-26	simplicio	+8.5s
2026-09-26	normal	+0.3s
2026-09-26	simplicio	+37.7s
2026-09-26	normal	+3.5s
2026-09-26	simplicio	-11.2s

Gerado automaticamente a partir de results.json (dados reais, sem números fabricados). Nenhuma chave de API foi impressa ou registrada neste relatório.

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-27 · Commit (main): f7f43e324 · Modo: batch (todas as tarefas em uma sessão) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

simplicio-cli 0.18.16 · simplicio-loop 3.43.16 · simplicio-mapper 0.26.34

Veredito: normal: 1/1 tarefas, 27.0s, US\$ 0.00330 | simplicio: 1/1 tarefas, 47.7s, US\$ 0.00839

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	1/1	1/1	
Tempo (s)	27.0	47.7	-20.7 (-76.6%)
Turnos de LLM	6	10	-4 (-66.7%)
Comandos executados	3	7	-4 (-133.3%)
... dos quais simplicio-*	0	3	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	15191	28552	-13361 (-88.0%)
Tokens prompt (cacheado)	40192	127872	
Tokens completion	617	1702	-1085 (-175.8%)
Tokens de raciocínio	181	695	-514 (-284.0%)
Custo (USD)	\$0.00330	\$0.00839	\$-0.00509 (-154.3%)
Invocações do checker pelo próprio agente	1	2	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	6	0	0	0
simplicio	10	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Modo batch: criação e edição acontecem em uma única sessão, então turnos, tempo e custo não são separáveis por tarefa. Os números somente criação / somente edição estão no relatório sequencial do mesmo conjunto (ex.: REPORT-t4.html) e no resumo de REPORT.html.

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000000350	0.0000002900	0.0000000010	-	-	2026-09-27T00:41:08.128783+00:00


Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.003299	\$0.000803	\$0.000532	\$0.000040	\$0.000231	\$0.001367	72.6%	1/1
simplicio	create	\$0.008390	\$0.001822	\$0.000999	\$0.000128	\$0.000695	\$0.004348	81.7%	1/1

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	+9.7s
2026-09-26	simplicio	-61.7s
2026-09-26	normal	+9.5s
2026-09-26	simplicio	-11.6s
2026-09-26	normal	-2.7s
2026-09-26	simplicio	-2.1s
2026-09-26	normal	+8.8s
2026-09-26	simplicio	+27.1s
2026-09-26	normal	+12.0s
2026-09-26	simplicio	-21.8s

2026-09-27	normal	+8.5s
2026-09-27	simplicio	-10.6s

Gerado automaticamente a partir de results.json (dados reais, sem números fabricados). Nenhuma chave de API foi impressa ou registrada neste relatório.

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-27 · Commit (main): f7f43e324 · Modo: sequencial (uma sessão por tarefa) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

simplicio-cli 0.18.16 · simplicio-loop 3.43.16 · simplicio-mapper 0.26.34

Veredito: normal: 4/4 tarefas, 136.5s, US\$ 0.04566 | simplicio: 4/4 tarefas, 283.9s, US\$ 0.04128

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	4/4	4/4	
Tempo (s)	135.8	283.2	-147.4 (-108.5%)
Turnos de LLM	18	45	-27 (-150.0%)
Comandos executados	3	30	-27 (-900.0%)
... dos quais simplicio-*	0	8	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	42525	66523	-23998 (-56.4%)
Tokens prompt (cacheado)	115456	564864	
Tokens completion	1713	5778	-4065 (-237.3%)
Tokens de raciocínio	326	5797	-5471 (-1678.2%)
Custo (USD)	\$0.04566	\$0.04128	\$0.00438 (9.6%)
Invocações do checker pelo próprio agente	0	2	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	18	0	0	0
simplicio	45	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Somente criação (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	2/2	2/2	
Tempo (s)	73.2	167.0	-93.8 (-128.2%)
Turnos de LLM	9	24	-15 (-166.7%)
Comandos executados	3	17	-14 (-466.7%)
... dos quais simplicio-*	0	4	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	19016	44063	-25047 (-131.7%)
Tokens prompt (cacheado)	68864	307840	
Tokens completion	970	2919	-1949 (-200.9%)
Tokens de raciocínio	240	3156	-2916 (-1215.0%)
Custo (USD)	\$0.01904	\$0.02704	\$-0.00800 (-42.0%)
Invocações do checker pelo próprio agente	0	1	

Somente edição (mesma sessão)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	2/2	2/2	
Tempo (s)	62.6	116.2	-53.5 (-85.4%)
Turnos de LLM	9	21	-12 (-133.3%)
Comandos executados	0	13	-13 (n/a)
... dos quais simplicio-*	0	4	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	23509	22460	1049 (4.5%)
Tokens prompt (cacheado)	46592	257024	
Tokens completion	743	2859	-2116 (-284.8%)
Tokens de raciocínio	86	2641	-2555 (-2970.9%)
Custo (USD)	\$0.02662	\$0.01424	\$0.01238 (46.5%)
Invocações do checker pelo próprio agente	0	1	

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.0000000350	0.0000002900	0.0000000010	-	-	2026-09-27T00:42:45.236287+00:00

Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)


Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.019040	\$0.001085	\$0.000666	\$0.000069	\$0.000351	\$0.002341	78.4%	2/2
normal	edit	\$0.026618	\$0.001110	\$0.000823	\$0.000047	\$0.000240	\$0.001584	66.5%	2/2
simplicio	create	\$0.027035	\$0.003612	\$0.001542	\$0.000308	\$0.001762	\$0.010467	87.5%	2/2

simplicio	edit	\$0.014242	\$0.002638	\$0.000786	\$0.000257	\$0.001595	\$0.008739	92.0%	2/2
-----------	------	------------	------------	------------	------------	------------	------------	-------	-----

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	+17.8s
2026-09-26	simplicio	-118.0s
2026-09-26	normal	+44.1s
2026-09-26	simplicio	-79.8s
2026-09-26	normal	+68.0s
2026-09-26	simplicio	+127.0s
2026-09-26	normal	+77.3s
2026-09-26	simplicio	+134.9s

Gerado automaticamente a partir de results.json (dados reais, sem números fabricados). Nenhuma chave de API foi impressa ou registrada neste relatório.

Benchmark A/B: mesmo agente, com vs sem a skill simplicio-loop

Modelo: openrouter/deepseek/deepseek-v4.1-flash · Data: 2026-09-27 · Commit (main): f7f43e324 · Modo: batch (todas as tarefas em uma sessão) · Política de esforço: opencode-managed (no per-call reasoning-effort control via the CLI)

simplicio-cli 0.18.16 · simplicio-loop 3.43.16 · simplicio-mapper 0.26.34

Veredito: normal: 4/4 tarefas, 111.5s, US\$ 0.00175 | simplicio: 4/4 tarefas, 135.2s, US\$ 0.01129

Comparação geral (agente normal vs agente com a skill simplicio-loop)

Métrica	normal	simplicio	Economia com simplicio
Tarefas concluídas	4/4	4/4	
Tempo (s)	111.5	135.2	-23.7 (-21.3%)
Turnos de LLM	6	20	-14 (-233.3%)
Comandos executados	3	11	-8 (-266.7%)
... dos quais simplicio-*	0	2	
CPU total (comandos, s)	0.00	0.00	0.00 (n/a)
Pico RAM (MB)	0.0	0.0	
Tokens prompt (não cacheado)	12195	27394	-15199 (-124.6%)
Tokens prompt (cacheado)	51968	347392	
Tokens completion	1151	2801	-1650 (-143.3%)
Tokens de raciocínio	240	2618	-2378 (-990.8%)
Custo (USD)	\$0.00175	\$0.01129	-\$0.00954 (-543.8%)
Invocações do checker pelo próprio agente	1	1	

Esforço de raciocínio por chamada de LLM (plan alto / execute baixo / review médio)

braço	default	low	medium	high
normal	6	0	0	0
simplicio	20	0	0	0

Somente criação e somente edição (tarefas da mesma sessão)

Modo batch: criação e edição acontecem em uma única sessão, então turnos, tempo e custo não são separáveis por tarefa. Os números somente criação / somente edição estão no relatório sequencial do mesmo conjunto (ex.: REPORT-t4.html) e no resumo de REPORT.html.

Preço por token (OpenRouter, ao vivo)

modelo	prompt	completion	cache read	cache write	raciocínio interno	obtido em
deepseek/deepseek-v4.1-flash	0.000000350	0.0000002900	0.0000000010	-	-	2026-09-27T00:50:12.789349+00:00


Custo real: cobrado (delta assentado) vs calculado pelos tokens (cache-aware)

Cobrado = delta assentado da chave OpenRouter (issue #1335: assentado é ``GET /api/v1/key`` sem variar por 3 leituras seguidas, nunca o primeiro movimento) ou, quando o uso nunca assenta, o próprio custo calculado (``cost\_source = computed-from-tokens``). Sinalizados = tarefas cujo custo cobrado divergiu do calculado em mais de 10%.

braço	tipo	cobrado	calculado	entrada não cacheada	entrada cacheada	saída	economia de cache	hit % de cache	sinalizados
normal	create	\$0.001754	\$0.000882	\$0.000427	\$0.000052	\$0.000403	\$0.001767	81.0%	1/2
normal	edit	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	0.0%	0/2
simplicio	create	\$0.011292	\$0.002878	\$0.000959	\$0.000347	\$0.001572	\$0.011811	92.7%	1/2
simplicio	edit	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	\$0.000000	0.0%	0/2

Gate de cache por chamada: OK (toda chamada do simplicio após a 1ª leu cache).

Gráficos



Histórico (comparação com execuções anteriores)

execução anterior	braço	Δ tempo total
2026-09-26	normal	-7.1s
2026-09-26	simplicio	-266.7s
2026-09-26	normal	+19.2s
2026-09-26	simplicio	-228.4s
2026-09-26	normal	+43.0s
2026-09-26	simplicio	-21.6s
2026-09-26	normal	+52.3s
2026-09-26	simplicio	-13.8s

2026-09-27	normal	-25.0s
2026-09-27	simplicio	-148.6s

Gerado automaticamente a partir de results.json (dados reais, sem números fabricados). Nenhuma chave de API foi impressa ou registrada neste relatório.